


AI study

RNN·LSTM· GRU

안동균

(지도교수 : 양선웅)

한양대학교 ERICA 로봇공학과



Intelligent Design
for Engineering
Applications Lab

지난 자료에서 코드를 통해 이해할 부분

같은 코드 · 같은 학습 조건인데 결과가 갈린 이유 ?

IMDB · RNN

정확도 0.50

LSTM/GRU 에 비해 현저히 낮은 정확도

MNIST · LSTM / GRU

정확도 0.97+

정상 학습

코드를 통해 이해할 수 있는 4 가지

- 1 RNN 의 근본 약점 (기울기 소실) 을 눈으로 볼 수 있는가 ?
- 2 시퀀스가 길어지면 RNN 은 정말 무너지는가 ?
- 3 하이퍼파라미터를 바꾸면 결과는 어떻게 변하는가 ?
- 4 이 교훈으로 지난주 IMDB 의 실패를 고칠 수 있는가 ?

실험 1

실험 2

실험 3

실험 4

각 실험은 가설 → 실험 → 결과 → 해석 순서로 진행했다 .

Part **1**
RNN


Part **2**
LSTM

Part **3**
GRU

Part **4**
실습 · 정리

순환신경망 개선 모델 : LSTM — 구조와 수식

셀 상태 (c_t) 라는 정보 고속도로를 두고 , 3 개의 게이트가 그 위의 정보 흐름을 통제한다 .



게이트 — 모두 σ , 출력 0~1

$$\begin{aligned} f_t &= \sigma(Wxhf \cdot x_t + Whhf \cdot h_{t-1} + bf) \\ i_t &= \sigma(Wxhi \cdot x_t + Whhi \cdot h_{t-1} + bi) \\ o_t &= \sigma(Wxho \cdot x_t + Whho \cdot h_{t-1} + bo) \end{aligned}$$

후보값 — $\tanh$, 출력 -1~1 (내용)

$$\tilde{c}_t = \tanh(Wxhg \cdot x_t + Whhg \cdot h_{t-1} + bg)$$

상태 갱신

$$\begin{aligned} c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \\ h_t &= o_t \odot \tanh(c_t) \end{aligned}$$

- ① 셀 상태 c_t 를 $\tanh$ 로 -1~1 로 누르고
- ② 출력 게이트 $o_t(0 \sim 1)$ 를 곱해 걸러낸다
- 지금 내보낼 정보만 h_t 에 담긴다

Forget f_t

과거 cell state 를 얼마나 유지할지
1 이면 완전 유지 · 0 이면 완전 삭제

Input $i_t \cdot \tilde{c}_t$

새 정보를 얼마나 (i_t), 무엇을 ($\tilde{c}_t$) 담을지
 $i_t = \text{양} \cdot \tilde{c}_t = \text{내용}$


Output o_t

cell state 중 무엇을 h_t 로 내보낼지
 $\tanh(c_t)$ 를 o_t 로 걸러서 출력

$\odot$ = 원소별 곱 (Hadamard)= 합성곱 . 셀 상태 c_t 는 활성화 함수 통과하지 않고 더하기만 하므로 장기 기억 , 은닉 상태 h_t 는 매 시점 꺼내 쓰는 단기 기억이다 .

LSTM 역전파 — RNN 과의 차이점

체인롤은 ‘의존의 사슬’ 을 ‘곱셈의 사슬’ 로 바꾼다 — h_t 가 h_{t-1} 에 의존하므로, 손실까지 거슬러 가려면 각 구간의 미분을 모두 곱해야 한다.



$$\partial J / \partial h_1 = \partial J / \partial h_t \times \partial h_t / \partial h_{t-1} \times \cdots \times \partial h_2 / \partial h_1$$

→ 구간이 T 개면 곱셈도 T 번. 그래서 구간마다 곱해지는 인자 ∂ (다음) ∂ (이전) 가 1 보다 작으면 지수적으로 소멸.

RNN — 그 인자는 두 조각의 곱

h_t 는 $\tanh$ 안에서 h_{t-1} 과 만난다

$$h_t = \tanh(z_t), \quad z_t = W_{xh} \cdot x_t + W_{hh} \cdot h_{t-1}$$

$$\partial h_t / \partial h_{t-1} = (\partial h_t / \partial z_t) (\partial z_t / \partial h_{t-1}) = \tanh'(z_t) \cdot W_{hh}$$

활성함수 미분 $\times$ 가중치 — 둘 다 1 보다 작기 쉽다

LSTM — 그 인자는 게이트 하나

c_t 는 덧셈으로 c_{t-1} 과 만난다

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

$$\partial c_t / \partial c_{t-1} = f_t \quad (\text{뒷항에는 } c_{t-1} \text{ 이 없어 } 0)$$

활성함수도 가중치도 없다 — $f_t \approx 1$ 이면 감쇠 없음

같은 체인롤인데 곱해지는 인자가 다르다 — RNN 은 $(1 \text{ 보다 작은 수})^T$ 로 소멸, LSTM 은 게이트만 누적. 이 차이를 실험 ①에서 측정한다.

실험 ① 기울기 소실을 눈으로 보다




가설 순수 RNN 은 먼 과거로 갈수록 기울기가 지수적으로 사라진다 . LSTM/GRU 는 완만하다 .

Part 1
RNN

Part 2
LSTM

Part 3
GRU

Part 4
실습 · 정리



왼쪽 $t=1$ 이 먼 과거 오른쪽으로 갈수록 최근

RNN에선 $h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1})$ 이므로 가중치 W_{hh} 이 계속 곱해지는 구조 $\rightarrow$ 1보다 작으면 0으로 수렴

LSTM은 똑같이 hidden state는 죽을지 몰라도 이전기억을 다음으로넘겨주는 cell state가 있고 이는 $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$ 이므로 $\partial c_t / \partial c_{t-1} = f_t$ 이고 forget gate를 통과한 값 f_t 는 0~1 연속값이라, 1에 가까우면 기울기가 거의 그대로 보존됨

오른쪽 그림은 망각게이트 b값을 0~2까지 올려본 결과이고 바이어스를 올릴수록 과거의 기울기를 기억하는 모습을 보임

실험 ② 시퀀스가 길어지면 무너지는가

가설 짧은 시퀀스에서는 RNN 도 쓸 만하지만 , 길어지면 RNN 만 붕괴한다 .

같은 MNIST 를 입력차원 D 로 쪼개 시퀀스 길이를 28 → 56 → 112 로 늘려가며 비교했다 .

짧은 시퀀스


T = 28 (28 열 × 28)

한 줄씩 읽기

긴 시퀀스

T = 112 (7 × 112)

잘게 쪼개 4 배 길게




짧으면 (T=28) 세 모델 차이가 작지만 , 길어질수록 (T=112) RNN 은 0.90→0.58 로 하락하고 LSTM/GRU 는 RNN 보다 정확도를 높게 유지 .

실험 ③ -1 학습률에 따른 정확도

가설 RNN 은 기울기가 불안정해 학습률에 매우 민감하다 . 너무 크면 발산 , 작으면 정체 .

학습률을 0.1~0.0001 로 바꿔가며 RNN 과 LSTM 을 비교했다 .



RNN

좁은 구간에서만 학습 — lr 이 크면 발산 , 작으면 정체

LSTM

넓은 범위에서 안정적으로 학습

하이퍼파라미터 튜닝 난이도 자체가 RNN 이 높다 — 지난주 IMDB 실패의 한 원인이기도 하다 .

Part 1
RNN

Part 2
LSTM

Part 3
GRU


Part 4
실습 · 정리

실험 ③ -2·3 은닉 차원과 층 수 — 크고 깊을수록 좋은가

가설 키우면 표현력이 늘지만, 어느 지점부터 수익이 줄고 비용만 커진다.

③-2 은닉 차원 (hidden_dim)


16 → 32 → 64 → 128 → 256



작을 때는 키울수록 정확도가 뚜렷이 오른다.
128 → 256 은 거의 평평 — **수확 체감**
무작정 키우면 시간 · 과적합 위험만 증가

③-3 층 수 (num_layers)

1 층 → 2 층 → 3 층



1 → 2 층 이득이 크지 않고,
3 층은 시간 · 파라미터만 증가
“**깊을수록 좋다**” 는 항상 참이 아니다

정답이 하나가 아니라 데이터 양과 함께 판단해야 하는 트레이드오프 — 실험으로 ‘적당한 지점’ 을 찾아야 한다.

Part 1
RNN


Part 2
LSTM

Part 3
GRU

Part 4
실습 · 정리

실험 ③ -4 양방향 (Bidirectional)

가설 앞→뒤와 뒤→앞을 모두 읽으면 문맥이 풍부해져 정확도가 오른다. 대신 계산량은 2 배.



MNIST 행 분류

0.920 → 0.920

이득 없음 (동률) = 의미없음

IMDB 텍스트 · RNN

0.593 → 0.627

+0.034

IMDB 텍스트 · LSTM

0.719 → 0.758

+0.039

관찰 MNIST 행 분류에서는 단방향과 양방향이 완전히 동률 (0.920) 이었지만, IMDB 텍스트에서는 RNN·LSTM 모두 0.03~0.04 상승.

왜 ? MNIST 는 마지막 은닉 상태에 28 행 정보가 이미 다 담겨 뒤→앞 읽기가 새 정보를 주지 않는다. 반면 텍스트는 뒤쪽 단어가 앞쪽 해석을 바꾸므로 ('not bad', 반전 표현) 역방향 문맥이 실제로 정보를 더한다.

하지만 계산량이 2 배 걸리는데 상승은 0.03~0.04 소폭 상승이므로 의미가 있는지는 시드 여러 개로 반복실험이 필요하다고 생각

Part 1
RNN

Part 2
LSTM

Part 3
GRU

Part 4
실습 · 정리

실험 ④ 지난주 IMDB 리뷰 데이터 학습 코드 수정본

원인 진단 패딩 처리 버그 + RNN 의 구조적 한계 → 버그를 고치고 셀만 교체해 재실험

지난주

0.51 정체

세 모델 모두 학습 실패

버그 수정 후 — 셋 다 학습 성공

RNN


0.62

LSTM

0.73

GRU

0.72



핵심은 최종 정확도가 아니라 **초반 학습 속도와 안정성** 이다 .

2 예폭 시점 — RNN 0.57 vs LSTM 0.64 vs GRU 0.65. RNN 은 느리고 출렁이며 중간에 하락하기도 했다 .

버그 수정 후 정확도에서 차이가 보였지만 200 단어는 RNN 이 확연히 도드라질정도의 차이는 없었음 . 진짜 격차는 더 길어질 때 드러난다 .

	실험	바꾼 것	핵심 발견
Part 1 RNN	① 기울기 소실	시퀀스 길이 T ($t=1 \sim 60$)	$t=1$ 기울기 RNN 4.19×10^{-16} vs LSTM 1.42×10^{-12} — 지수적 소멸
	② 시퀀스 길이	$T = 28 \rightarrow 56 \rightarrow 112$	길수록 RNN 만 $0.90 \rightarrow 0.58$ 하락 , LSTM/GRU 는 높게 유지
Part 2 LSTM	③-1 학습률	$0.1 \sim 0.0001$	RNN 은 좁은 구간에서만 학습 , LSTM 은 넓은 범위에서 안정
	③-2 은닉 차원	$16 \rightarrow 256$ (RNN·LSTM)	16 배 키워도 격차 $+0.11 \rightarrow +0.12$ — 용량으로 메워지지 않음
	③-3 층 수	$1 \rightarrow 3$ 층 (RNN·LSTM)	RNN 은 3 층에서 0.75 로 하락 , LSTM 은 0.91 유지
Part 3 GRU	③-4 양방향	단방향 vs 양방향	MNIST 0.920 동률 , IMDB 만 $+0.03 \sim 0.04$ — 과제에 따라 갈림
	④ IMDB 수정본	패딩 수정 + 셀 교체	RNN $0.62 < \text{GRU } 0.72 \cdot \text{LSTM } 0.73$ — 초반 학습 속도 · 안정성 차이
Part 4 실습 · 정리	모든 결론은 가설을 세우고 조건을 바꿔 얻은 결과에서 나왔다 .		

Part 1 RNN
Part 2 LSTM
Part 3 GRU
Part 4 실습 · 정리

RNN 의 한계는 코드가 아니라 **구조 (기울기 소실)** 에 있다 .
 시퀀스가 길어질수록 이 한계가 드러나며 , **셀 상태라는 우회로** 를 둔 LSTM/GRU 가 이를 해결한다 .
 하이퍼파라미터는 정답이 하나가 아니라 **실험으로 찾아야 하는 트레이드오프** 다 .

	RNN	LSTM	GRU
게이트 수	0	3	2
상태 (hidden state)	h	h, C (셀 상태)	h
장기 의존성	약함	강함	강함
파라미터 / 속도	적음 / 빠름	많음 / 느림	중간 / 빠름
반환값 (PyTorch)	out, h	out, (h, c)	out, h
언제 쓰나	짧은 시퀀스	성능 우선 · 긴 시퀀스	성능 비슷 · 경량

성능은 LSTM $\approx$ GRU. 하지만 GRU 가 LSTM 보다 파라미터가 훨씬 작기 때문에 training time 이 절약됨
 → 그럼 GRU 가 무조건 성능이 좋은가? → Task 에 따라 천차만별
 따라서 둘 다 돌려보고 데이터 · 태스크에 맞게 고른다 .

But LSTM 과 GRU 가 RNN 보다는 성능이 좋음을 보장한다

Any Questions?

이름 안동균

소속 한양대학교 로봇공학과

이메일 ehdrbs123450@hanyang.ac.kr



*Intelligent Design
for Engineering
Applications Lab*

